

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В АРСЕНАЛЕ НАРУШИТЕЛЯ: АНАЛИЗ НОВЫХ ВЫЗОВОВ ИНФОРМАЦИОННОЙ БЕЗОПАСНОСТИ

Коркин И. Ю.¹, Туманов Ю. М.², Докучаева О. Н.³

DOI: 10.21681/2311-3456-2026-4-64-70

Цель исследования: анализ современных угроз информационной безопасности, возникающих в связи с использованием технологий искусственного интеллекта в противоправной деятельности, а также систематизация методов защиты систем искусственного интеллекта (ИИ-систем), прежде всего больших языковых моделей.

Метод(ы) исследования: использованы методы системного анализа, сравнительного анализа научных публикаций и практических кейсов, а также методы обобщения современных исследований в области безопасности искусственного интеллекта (AI Security). Применён аналитический подход к классификации угроз и механизмов защиты.

Результат(ы) исследования: установлено, что внедрение генеративных и автономных ИИ-систем приводит к качественной трансформации ландшафта киберугроз. Выявлены ключевые направления злоумышленного применения ИИ: автоматизированная генерация фишингового и мультимедийного контента, создание дипфейков, разработка и применение вредоносного программного обеспечения, использование подхода «just-in-time» для генерации и запуска вредоносных модулей с помощью сторонних сервисов, реализующих большие языковые модели (Large Language Models, LLM-сервисы), а также использование систем ИИ для анализа уязвимостей и совершенствования техник нарушителей. Отдельное внимание уделено угрозам, направленным на сами ИИ-системы: атакам типа prompt injection, «отравлению» обучающих данных, извлечению конфиденциальной информации через вывод модели (model inference), а также состязательным атакам. Систематизированы технические и организационные меры противодействия, включающие фильтрацию пользовательских запросов, применение методов состязательного обучения, внедрение механизмов дифференциальной приватности, ограничение доступа к API, детектирование синтетического контента и использование цифровых водяных знаков. Обоснована необходимость комплексного подхода к обеспечению безопасности, сочетающего инженерные решения и совершенствование нормативно-правового регулирования.

Научная новизна работы заключается в комплексной классификации угроз, где ИИ рассматривается одновременно как инструмент кибератак и как объект целенаправленных атак. Предложено системное объединение технических и правовых мер защиты в рамках единой модели обеспечения безопасности ИИ.

Ключевые слова: кибербезопасность; киберугрозы; большие языковые модели; генеративный ИИ; фишинговые атаки; дипфейки; состязательные атаки; защита ИИ, автономные ИИ-агенты.

Введение

Стремительное развитие технологий искусственного интеллекта значительно воздействует на различные сектора экономики, включая сферу информационной безопасности, где наблюдается трансформация как механизмов защиты, так и инструментов реализации угроз. Так, системы на базе искусственного интеллекта (ИИ-системы) способны повысить скорость работы пользователя путём автоматизации рутинных задач, улучшить анализ данных и принимать решения, однако их массовое внедрение сопровождается и новыми рисками. Как отмечают исследователи, современные ИИ-инструменты, такие как, сервисы на базе больших языковых моделей типа ChatGPT, приносят не только пользу, но и порождают серьёзные угрозы криминального характера, формируют новый класс рисков, поскольку позволяют масштабировать социальную инженерию,

ускорять анализ уязвимостей, снижать порог входа в разработку вредоносного кода и усложнять атрибуцию противоправной деятельности [1–4].

Иными словами сами ИИ-системы становятся самостоятельной целью воздействия, поскольку большие языковые модели и иные модели машинного обучения уязвимы к атаке типа «prompt injection», утечке данных, извлечению параметров, состязательным примерам и многим другим видам атак [2, 3, 5–8], а искусственный интеллект сегодня выступает одновременно как субъект киберугроз (когда используется нарушителями для проведения атак), так и объект киберугроз (когда сами ИИ-системы становятся целью нападения).

Рост числа инцидентов с применением ИИ уже привлёк внимание многих специалистов по информационной безопасности. Например, появились

1 Коркин Игорь Юрьевич, кандидат технических наук, ведущий программист, «Positive Technologies». Москва, Россия. E-mail: igor.korkin@gmail.com

2 Туманов Юрий Михайлович, кандидат технических наук, ведущий эксперт, ПАО «Ростелеком». Москва, Россия. E-mail: 3.14hell@gmail.com

3 Докучаева Оксана Николаевна, начальник отдела аналитического обеспечения и внутреннего контроля Управления ИБ ФГБУ «ЦСП» ФМБА России. Москва, Россия. E-mail: Dokuchaevaon@ithub.ru

исследования и рейтинги уязвимостей, специфичных для ИИ-систем: отдельно опубликован OWASP Top 10 для приложений на основе больших языковых моделей. Формируется новая отрасль знаний – безопасность ИИ (AI Security), включающая анализ угроз, методов атаки и способов защиты, применительно к алгоритмам машинного обучения. Настоящая работа ставит своей целью обобщить сведения о популярных видах таких угроз и соответствующих мерах защиты. В разделе 1 рассмотрены основные сценарии злоумышленного использования систем ИИ (ИИ как «оружие» преступников), в разделе 2 – методы обеспечения безопасности самих интеллектуальных моделей, прежде всего LLM (ИИ как «мишень» для атак), а в последующих разделах описаны популярные уязвимости больших языковых моделей и правовые аспекты противодействия подобным практикам [9–12].

Угрозы, связанные с преступным использованием ИИ-технологий

Развитие доступных ИИ-инструментов заметно расширило арсенал киберпреступников. Если раньше проведение целевых атак требовало значительных ресурсов и экспертизы, то теперь частично их роль перенимают алгоритмы машинного обучения. Злоумышленники экспериментируют с интеграцией ИИ в различные этапы атак, что повышает скорость подготовки и масштабность компьютерных атак, а также значительно снижает требования к квалификации исполнителя [4, 9, 13, 14]. Ниже приведены наиболее распространённые угрозы, обусловленные применением ИИ нарушителями:

1) Генерация текстового и мультимедиа фишингового контента

Современные генеративные модели способны создавать содержимое различного мультимедиа формата: текст, аудио и видео практически неотличимого качества. Это открывает новые возможности для социальной инженерии. В частности, с помощью нейросетей преступники генерируют реалистичные дипфейки – поддельные видео/аудио, имитирующие внешность и голос реальных людей. Такие материалы сложно отличить от подлинных, и они могут использоваться для дискредитации публичных лиц либо мошенничества (например, имитации голоса руководителя для обмана сотрудников). Аналогично, языковые модели используются для массового фишинга: ИИ позволяет автоматически составлять грамотные, контекстно релевантные письма на разных языках и тем самым значительно повышать масштаб рассылки и процент отклика на мошеннические сообщения. В результате существующие популярные мошеннические схемы получают качественно новый

уровень персонализации: атакующий может имитировать голос руководителя, родственника или иного значимого лица, а также комбинировать текстовые и аудиовизуальные подделки в рамках одной атаки [4, 9–12].

2) Автоматизация разработки вредоносного ПО

Генеративные модели программного кода позволяют ускорить создание и совершенствование вредоносных программ и эксплоитов. Мошенники могут поручить ИИ сгенерировать исходные листинги вредоносных скриптов, подобрать эксплойт под известную уязвимость или даже обнаружить уязвимости путём анализа листинга исходного кода. По оценкам экспертов, ИИ способен существенно сократить требуемые навыки и время для разработки сложных экземпляров вредоносного кода. Хотя на данный момент полностью автономные кибератаки остаются редкостью, зафиксированы случаи, когда ИИ-ассистенты применялись для тестирования вредоносных, обфускации кода и генерирования множества вариантов атаки. Полноценная автономная разработка сложного вредоносного инструментария по-прежнему требует участия человека, ИИ уже заметно сокращает время подготовки отдельных компонентов атаки и облегчает их адаптацию под конкретную среду [7, 9, 13–14].

3) Интеграция автономных ИИ-агентов в архитектуру вредоносного ПО

В настоящее время эксперты по безопасности отмечают тренд усложнения архитектуры вредоносных программ за счёт интеграции автономных ИИ-агентов. В отличие от ранее популярных образцов ВПО, содержащих заранее реализованный набор функциональных плагинов-расширений (например, сбор информации о недавних документах пользователя, получение списка запущенных процессов), новые решения позволяют передавать исполнительную логику сторонним ИИ-агентам, которые реализуют модель искусственного интеллекта.

В данной модели взаимодействия нарушитель передает агенту ВПО целевые установки высокого уровня в текстовом виде, вместо скомпилированного машинного кода. ИИ-агент, анализируя текущую конфигурацию системы, самостоятельно генерирует код сценариев и скрипты, необходимые для выполнения задачи.

Подобный подход нивелирует возможности сигнатурного анализа, поскольку финальный вредоносный код отсутствует до момента его генерации непосредственно в атакуемой системе. Эксперты анализу вредоносного ПО лишаются возможности проведения технического исследования самого вредоносного модуля. Это требует смещения фокуса

защиты в сторону поведенческого мониторинга и выявления аномалий при активном взаимодействии с ИИ-сервисами в течение длительного времени, что качественно и количественно меняет технический облик средств защиты информации.

Приведённые примеры подтверждают крайне высокий криминогенный потенциал технологий искусственного интеллекта. По мере удешевления и распространения таких средств число попыток их злонамеренного применения будет расти. Согласно обзорам, массовое внедрение генеративного ИИ может вывести угрозы дезинформации, мошенничества и кибератак на качественно новый уровень. Уже сегодня мошенники активно используют нейросети в своих схемах, а государства и компании вынуждены вовлекаться в своеобразную «гонку вооружений» в сфере ИИ. В этих условиях первоочередной задачей становится разработка адекватных методов противодействия новым угрозам – как технологических, так и организационно-правовых.

Методы и техники атак на программные реализации больших языковых моделей и других систем искусственного интеллекта

Рост числа атак, нацеленных на сами системы ИИ, обусловил появление особого направления исследований по обеспечению безопасности ИИ-систем (защиты алгоритмов машинного обучения от вредоносных воздействий). Большие языковые модели, как один из наиболее сложных и широко применяемых типов ИИ, уязвимы к ряду специфических атак и требуют внедрения дополнительных мер защиты на всех этапах жизненного цикла – от обучения до эксплуатации. Ниже рассмотрены ключевые угрозы для LLM и соответствующие методы защиты:

1) Атаки через ввод вредоносных запросов (prompt injection)

Злоумышленник формирует специальный ввод (промпт), который заставляет языковую модель игнорировать заложенные ограничения и генерировать нежелательный контент (например, раскрыть конфиденциальные данные или предоставить инструкции для совершения преступления). Подобные атаки эксплуатируют уязвимости модели в интерпретации инструкций. Для противодействия используется фильтрация и мониторинг вводимых запросов: система анализирует запрос на наличие запрещённых паттернов и либо отклоняет его, либо модифицирует перед передачей модели. Разрабатываются техники «иммунизации» LLM, при которых в ходе обучения модель знакомится с примерами атакующих промптов и учится их нейтрализовать. Важным является и совершенствование модерации выводов модели – использование встроенных правил и пост-процессоров,

не допускающих выдачу конфиденциальной или опасной информации.

2) «Отравление» обучающих данных (data poisoning)

На этапе обучения злоумышленник может внедрить в датасет заведомо искажённые или специально помеченные данные, что приведёт к деградации качества модели либо к появлению в ней скрытых «триггеров». Например, добавив достаточно экземпляров с определённой меткой, атакующий добивается неправильной классификации или генерации при наличии в запросе этого триггера. Успешная атака нарушает целостность и корректность модели. Для защиты рекомендуется тщательно проверять и фильтровать данные перед обучением, использовать разнообразные и репрезентативные выборки, а также применять методы состязательного обучения – включения в тренировочный набор искусственно сгенерированных «враждебных» примеров, чтобы повысить устойчивость модели. В научной литературе отмечается эффективность защитных подходов, закладываемых ещё на этапе создания и обучения модели, – выборочных методов обучения, специальных требований к источникам данных и др.

3) Атаки типа «логический вывод» (model inference) и кража модели

Даже без прямого доступа к коду нейросети злоумышленники способны извлечь из неё ценную информацию. Посылая множество тщательно подобранных запросов к модели-«чёрному ящику» и анализируя ответы, можно восстановить некоторые фрагменты обучающих данных (угроза конфиденциальности) или воспроизвести саму модель путем последовательных запросов (угроза интеллектуальной собственности). Особенно остро проблема стоит для LLM, обученных на частных корпоративных данных – утечка такой информации через ответы модели представляет серьёзный риск. Контрмеры включают ограничение доступа к API модели (аутентификация клиентов, квоты на число запросов), использование методов дифференциальной приватности при обучении (встраивание «шума» в веса модели, снижающее утечку данных), а также отслеживание аномалий в паттернах запросов, указывающих на попытки массового скачивания знаний модели.

4) Состязательные атаки (adversarial examples)

Данная категория угроз наиболее изучена для систем компьютерного зрения, но в общем виде применима и к LLM. Атакующий генерирует специально модифицированный ввод, не отличимый для человека от обычного, который заставляет модель выдать ошибочный результат. В случае с визуальными моделями это едва заметные шумы в изображениях,

сбивающие классификатор, для языковой модели – ввод с особыми токенами или структурой, приводящий к нелепому или опасному ответу. Состязательные атаки фактически эксплуатируют ограничения и погрешности в модели. Для защиты применяются методы оборонительной дистилляции (специальная процедура переподготовки модели, сглаживающая её реакцию на малые возмущения входа) и введение случайности в ответы (например, небольшое рандомизированное изменение вероятностей выбора токенов), что затрудняет подбор идеального «враждебного» примера. Кроме того, развивается направление создания внешних средств – детекторов атак, которые параллельно с основной моделью оценивают входные данные и результаты на предмет аномалий, сигнализируя о возможной атаке.

Отдельно следует отметить меры противодействия злоупотреблениям ИИ на уровне контента. Поскольку значительная часть новых угроз связана с генерированием правдоподобных поддельных данных (фейковых изображений, видео, текстов), важным направлением защиты стало распознавание синтетического контента. Разрабатываются алгоритмы анализа, способные отличить изображение или аудио, созданное нейросетью: например, по специфическим артефактам на пиксельном уровне или неестественным цифровым шумам, остающимся после работы генеративной модели. Параллельно индустрия движется к внедрению механизмов watermarking – добавления специальных метаданных или водяных знаков в генерируемые ИИ материалы, что позволит верифицировать их происхождение. Большие компании (например, OpenAI) уже экспериментируют с метками в выводе LLM, упрощающими последующую идентификацию ИИ-контента. Ещё один слой защиты – правовой. В ряде стран инициированы законодательные меры, вводящие ответственность за распространение ИИ-сгенерированных фейков и обязующие пометать сгенерированный контент. Также обсуждаются международные кодексы и стандарты «Responsible AI», предусматривающие этические нормы создания и применения ИИ-технологий.

Таким образом, обеспечение безопасности больших языковых моделей и других ИИ-систем требует комбинации методов: совершенствования самой архитектуры и процессов обучения моделей, создания вокруг них защищённой инфраструктуры (контроль доступа, мониторинг), использования вспомогательных средств обнаружения атак, а также развития нормативно-правовой базы. Комплексный подход с учётом перечисленных мер позволит существенно снизить риски, связанные с ИИ, и сохранить доверие пользователей к данным технологиям.

Правовые аспекты расследования преступлений, совершённых с использованием систем искусственного интеллекта

1) Проблема определения субъекта ответственности

Использование технологий искусственного интеллекта в противоправной деятельности создаёт новые вызовы для правоприменительной практики. В отличие от традиционных программных средств, современные ИИ-системы способны автономно генерировать контент, принимать решения и адаптироваться к изменяющимся условиям. В связи с этим возникает вопрос о распределении юридической ответственности между различными участниками экосистемы ИИ.

2) Потенциальные субъекты ответственности

В контексте расследования преступлений с применением ИИ можно выделить несколько возможных субъектов ответственности:

- **непосредственный пользователь ИИ-системы.** Основная ответственность, как правило, должна возлагаться на лицо, использующее систему искусственного интеллекта для совершения противоправных действий. В данном случае ИИ выступает лишь инструментом преступления, аналогично традиционному программному обеспечению;
- **разработчики ИИ-систем.** Вопрос ответственности разработчиков может возникать в случаях, когда программный продукт изначально создаётся с учётом возможности его противоправного использования или содержит уязвимости, позволяющие обходить механизмы безопасности. Однако в большинстве случаев разработчики не могут нести ответственность за действия пользователей при условии соблюдения требований безопасности и добросовестной разработки;
- **компании-владельцы ИИ-платформ.** Организации, предоставляющие доступ к ИИ-сервисам (например, LLM-платформам), могут нести ответственность в части: внедрения механизмов модерации, ограничения вредоносных сценариев использования, мониторинга злоупотреблений сервисами;
- **провайдеры интернет-инфраструктуры.** Интернет-провайдеры и облачные платформы обычно рассматриваются как посредники передачи данных и не несут прямой ответственности за действия пользователей, за исключением случаев игнорирования требований правоохранительных органов или хранения противоправного контента.

3) Проблемы доказывания преступлений с использованием ИИ

Расследование таких преступлений осложняется рядом факторов:

Техническая угроза	Потенциальная квалификация (УК РФ)	Проблемы доказывания
Генерация дипфейков	ст. 128.1, 159, 272 УК РФ	Идентификация источника, экспертиза синтетического контента
Атаки типа «prompt injection» для кражи персональных данных	ст. 272, 183 УК РФ	Фиксация вектора атаки, атрибуция через логи API

- генерация вредоносного контента в реальном времени;
- использование LLM-сервисов через API;
- распределённая архитектура облачных сервисов;
- трудности идентификации конкретного пользователя.

4) Перспективы правового регулирования

В настоящее время в ряде стран разрабатываются нормативные акты, направленные на регулирование применения технологий искусственного интеллекта. Ключевыми направлениями такого регулирования являются:

- обязательная маркировка ИИ-сгенерированного контента;
- требования к безопасности и тестированию ИИ-систем;
- ответственность за распространение дипфейков;
- стандарты Responsible AI.

Экспертное сообщество юристов подчёркивает, что ИИ должен рассматриваться не как субъект права, а как инструмент повышенной опасности, что требует разработки специальных режимов регулирования, аналогичных регулированию сложных технических систем.

Заключение

Инновационные технологии искусственного интеллекта становятся не только драйвером прогресса, но и источником новых киберугроз. Проведённый анализ показал, что ИИ как инструмент злоумышленников способен качественно усилить традиционные атаки (фишинг, распространение дезинформации, взлом информационных систем), повысив их масштаб, скрытность и эффективность за счёт автоматизации и сложности обнаружения. Одновременно ИИ как цель атак сам нуждается в защите: методы атак на алгоритмы машинного обучения (в частности, на LLM) включают намеренное искажение входных

данных, манипулирование обучающими выборками, выживание скрытой информации из моделей. Подобные угрозы безопасности ИИ-систем обусловлены нарушением базовых требований к данным и функционированию моделей, что может приводить к деградации их работы и утечке конфиденциальных сведений.

Для нейтрализации обозначенных рисков необходимо развигать соответствующие меры защиты. К их числу относятся: предобработка и фильтрация данных (как входных запросов, так и обучающих выборок); архитектурные решения, повышающие устойчивость моделей (например, включение в обучение adversarial-примеров, использование защитной дистилляции); ограничение доступа и мониторинг аномалий при эксплуатации ИИ-сервисов; внедрение систем детектирования ИИ-сгенерированного контента и меток в таком контенте; совершенствование нормативной базы оборота ИИ-технологий. Необходимо учитывать, что технологии и способы их атакующей эксплуатации стремительно эволюционируют – следовательно, системы защиты должны постоянно совершенствоваться, опираясь на результаты актуальных научных исследований.

Безопасность ИИ – новая междисциплинарная проблема, затрагивающая технические аспекты, право и управление. Отсутствие координации между этими сферами может привести к запаздыванию реакции на возникающие угрозы. Поэтому для эффективного противодействия ИИ-угрозам следует объединять усилия специалистов по кибербезопасности, разработчиков ИИ и законодательных органов. Только комплексный и проактивный подход обеспечит устойчивое и безопасное развитие искусственного интеллекта, при котором его преимущества будут использованы без ущерба для общества и информационной безопасности.

Литература

1. Карцхия А. А., Макаренко Г. И. Правовые проблемы применения искусственного интеллекта в России // Правовая информатика. – 2024. – № 1. – С. 4–19. – DOI: 10.21681/1994-1404-2024-1-4-1.
2. Гарбук С. В. Специальная модель безопасности создания и применения систем искусственного интеллекта // Вопросы кибербезопасности. – 2024. – № 1 (59). – С. 15–23. – DOI: 10.21681/2311-3456-2024-1-15-23.

3. Котенко И. В., Саенко И. Б., Лаута О. С., Васильев Н. А., Садовников В. Е. Атаки и методы защиты в системах машинного обучения: анализ современных исследований // Вопросы кибербезопасности. – 2024. – № 1 (59). – С. 24–37. – DOI: 10.21681/2311-2024-1-24-37.
4. Мещеряков Р. В., Мельников С. Ю., Пересыпкин В. А., Хорев А. А. Перспективные направления применения технологий искусственного интеллекта при защите информации // Вопросы кибербезопасности. – 2024. – № 4 (62). – С. 2–12. – DOI: 10.21681/2311-3456-2024-4-02-12.
5. Мударова Р. М., Намиот Д. Е. Противодействие атакам типа инъекция подсказок на большие языковые модели // International Journal of Open Information Technologies. – 2024. – Т. 12. – № 5. – С. 39–48.
6. Зырянова И. Н., Чернавский А. С., Трубачев С. О. Prompt injection – проблема лингвистических уязвимостей больших языковых моделей на современном этапе // Научный результат. Вопросы теоретической и прикладной лингвистики. – 2024. – Т. 10. – № 4. – С. 40–52.
7. Котенко И. В., Абраменко Г. Т. Использование больших языковых моделей для поиска угроз кибербезопасности на основе методов глубокого обучения: анализ современных исследований // Правовая информатика. – 2024. – № 3. – С. 32–42. – DOI: 10.24682/1994-1404-2024-3-32-42.
8. Yao Y., Duan J., Xu K., Cai Y., Sun Z., Zhang Y. A survey on large language model (LLM) security and privacy: The Good, The Bad, and The Ugly. // High-Confidence Computing. – 2024. – Vol. 4. – Issue 2. – Art. 100211. – DOI: 10.1016/j.hcc.2024.100211.
9. Намиот Д. Е. О кибератаках с помощью систем искусственного интеллекта // International Journal of Open Information Technologies. – 2024. – Т. 12. – № 9. – С. 132–141.
10. Кобец П. Н. Причинный комплекс возникновения криминальных рисков, вызванных применением технологий искусственного интеллекта, и превентивные меры по их предупреждению // Юридическая наука и практика: Вестник Нижегородской академии МВД России. – 2024. – № 1 (61). – С. 80–85. – DOI: 10.36511/2078-5356-2024-1-80-85.
11. Ефремова М. А., Русскевич Е. А. Дипфейк (deepfake) и уголовный закон // Вестник Казанского юридического института МВД России. – 2024. – Т. 15. – № 2 (56). – С. 97–105. – DOI: 10.37973/VESTNIKKUI-2024-56-13.
12. Jabir R., Le J., Nguyen C. Phishing Attacks in the Age of Generative Artificial Intelligence: A Systematic Review of Human Factors // AI. – 2025. – Vol. 6. – No. 8. – Art. 174. – DOI: 10.3390/ai6080174.
13. Намиот Д. Е., Ильюшин Е. А. Искусственный интеллект в кибербезопасности: поиск вредоносного программного обеспечения // International Journal of Open Information Technologies. – 2024. – Т. 12. – № 6. – С. 143–149.
14. Самонов А. В., Бурова И. О. Методика разработки автоматизированных средств генерации программного кода посредством настройки больших языковых моделей // Вопросы кибербезопасности. – 2024. – № 3 (61). – С. 68–75. – DOI: 10.21681/2311-3456-2024-3-68-75.

ARTIFICIAL INTELLIGENCE IN THE ARSENAL OF AN INTRUDER: ANALYSIS OF NEW CHALLENGES TO INFORMATION SECURITY

Korkin I. Yu.⁴, Tumanov Yu. M.⁵, Dokuchaeva O. N.⁶

Keywords: cybersecurity; cyber threats; large language models; generative AI; phishing attacks; deepfakes; adversarial attacks; AI protection, autonomous AI agents.

The purpose of the research is to analyze modern threats to information security arising in connection with the use of artificial intelligence technologies in illegal activities, as well as to systematize methods for protecting artificial intelligence systems (AI systems), primarily large language models.

Research method(s): methods of system analysis, comparative analysis of scientific publications and practical cases, as well as methods of generalization of modern research in the field of artificial intelligence security (AI Security) are used. An analytical approach to the classification of threats and protection mechanisms is applied.

Result(s) of the study: it was established that the introduction of generative and autonomous AI systems leads to a qualitative transformation of the cyber threat landscape. The key areas of malicious use of AI are identified: automated generation of phishing and multimedia content, creation of deepfakes, development and use of malicious software, use of the «just-in-time» approach to generate and launch malicious modules using third-party services that implement Large Language Models (LLM services), as well as the use of AI systems to analyze vulnerabilities and improve the techniques of violators. Special attention is paid to threats aimed at AI systems themselves: prompt injection attacks, «poisoning» of training data, extraction of confidential information through model inference, as well as adversarial attacks. Technical and organizational countermeasures have been systematized, including filtering user requests, using adversarial learning methods, introducing differential privacy mechanisms, restricting access to APIs, detecting synthetic content and using

4 **Igor Yu. Korkin**, Ph.D. in Engineering, Lead Programmer, Positive Technologies. Moscow, Russia. E-mail: igor.korkin@gmail.com

5 **Yuri M. Tumanov**, Ph.D. in Technical Sciences, Leading Expert, Rostelecom PJSC. Moscow, Russia. E-mail: 3.14hell@gmail.com

6 **Oksana N. Dokuchaeva**, Head of the Department of Analytical Support and Internal Control of the Information Security Department of the Federal State Budgetary Institution «Center for Strategic Planning» of the Federal Medical and Biological Agency of Russia of the Federal Medical and Biological Agency of Russia. Moscow, Russian Federation. E-mail: Dokuchaevaon@ithub.ru

digital watermarks. The need for an integrated approach to ensuring safety, combining engineering solutions and improvement of legal regulation, is substantiated.

The scientific novelty of the work lies in the comprehensive classification of threats, where AI is considered both as a tool of cyberattacks and as an object of targeted attacks. A systematic unification of technical and legal protection measures within the framework of a single model for ensuring AI security is proposed.

References

1. Karchiya A. A., Makarenko G. I. Pravovye problemy primeneniya iskusstvennogo intellekta v Rossii // Pravovaya informatika. – 2024. – No. 1. – Pp. 4–19. – DOI: 10.21681/1994-1404-2024-1-4-1.
2. Garbuk S. V. Special'naya model' bezopasnosti sozdaniya i primeneniya sistem iskusstvennogo intellekta // Voprosy kiberbezopasnosti. – 2024. – № 1 (59). – Pp. 15–23. – DOI: 10.21681/2311-3456-2024-1-15-23.
3. Kotenko I. V., Saenko I. B., Lauta O. S., Vasil'ev N. A., Sadovnikov V. E. Ataki i metody zashchity v sistemah mashinnogo obucheniya: analiz sovremennykh issledovaniy // Voprosy kiberbezopasnosti. – 2024. – No. 1 (59). – Pp. 24–37. – DOI: 10.21681/2311-2024-1-24-37.
4. Meshcheryakov R. V., Mel'nikov S. Yu., Peresypkin V. A., Horev A. A. Perspektivnye napravleniya primeneniya tehnologiy iskusstvennogo intellekta pri zashchite informatsii // Voprosy kiberbezopasnosti. – 2024. – No. 4 (62). – Pp. 2–12. – DOI: 10.21681/2311-3456-2024-4-02-12.
5. Mudarova R. M., Namiot D. E. Protivodejstvie atakam tipa in'ektsiya podskazok na bol'shie yazykovye modeli // International Journal of Open Information Technologies. – 2024. – V. 12. – No. 5. – Pp. 39–48.
6. Zyryanova I. N., Chernavskij A. S., Trubachev S. O. Prompt injection – problema lingvisticheskikh uyazvimostey bol'shih yazykovykh modelej na sovremennom eh tape // Nauchnyy rezul'tat. Voprosy teoreticheskoy i prikladnoy lingvistiki. – 2024. – V. 10. – No. 4. – Pp. 40–52.
7. Kotenko I. V., Abramenko G. T. Ispol'zovanie bol'shih yazykovykh modelej dlya poiska ugroz kiberbezopasnosti na osnove metodov glubokogo obucheniya: analiz sovremennykh issledovaniy // Pravovaya informatika. – 2024. – No. 3. – Pp. 32–42. – DOI: 10.24682/1994-1404-2024-3-32-42.
8. Yao Y., Duan J., Xu K., Cai Y., Sun Z., Zhang Y. A survey on large language models (LLM) security and privacy: The Good, The Bad, and The Ugly. // High-Confidence Computing. – 2024. – Vol. 4. – Issue 2. – Art. 100211. – DOI: 10.1016/j.hcc.2024.100211.
9. Namiot D. E. O kiberatakah s pomoshch'yu sistem iskusstvennogo intellekta // International Journal of Open Information Technologies. – 2024. – V. 12. – No. 9. – Pp. 132–141.
10. Kobec P. N. Prichinnyj kompleks vozniknoveniya kriminal'nykh riskov, vyzvannykh primeneniem tehnologiy iskusstvennogo intellekta, i preventivnye mery po ih preduprezhdeniyu // Yuridicheskaya nauka i praktika: Vestnik Nizhegorodskoj akademii MVD Rossii. – 2024. – No. 1 (61). – Pp. 80–85. – DOI: 10.36511/2078-5356-2024-1-80-85.
11. Efremova M. A., Russkevich E. A. Dipfejk (deepfake) i ugolovnyy zakon // Vestnik Kazanskogo yuridicheskogo instituta MVD Rossii. – 2024. – V. 15. – No. 2 (56). – Pp. 97–105. – DOI: 10.37973/VESTNIKKUI-2024-56-13.
12. Jabir R., Le J., Nguyen C. Phishing Attacks in the Age of Generative Artificial Intelligence: A Systematic Review of Human Factors // AI. – 2025. – Vol. 6. – No. 8. – Art. 174. – DOI: 10.3390/ai6080174.
13. Namiot D. E., Il'yushin E. A. Iskusstvennyy intellekt v kiberbezopasnosti: poisk vredonosnogo programmnoho obespecheniya // International Journal of Open Information Technologies. – 2024. – V. 12. – No. 6. – Pp. 143–149.
14. Samonov A. V., Burova I. O. Metodika razrabotki avtomatizirovannykh sredstv generatsii programmnoho koda posredstvom nastrojki bol'shih yazykovykh modelej // Voprosy kiberbezopasnosti. – 2024. – No. 3 (61). – Pp. 68–75. – DOI: 10.21681/2311-3456-2024-3-68-75.

